

SmartClearance TN — Note de synthèse

Hackathon National « IA & Finances Publiques » · 25-26 septembre 2026 **Défi principal : T6** — Détection d'anomalies par IA (pièces comptables, déclarations) **Défi complémentaire : T17** — Analyse prédictive et prix de référence **Équipe The Inspectors**
— Yassine Ferjani · Mariem Trabelsi

1. Le défi traité

Le contrôle documentaire reste manuel. La DDM, le manifeste, le TCE et le DCT sont normalisés en EDIFACT dans SINDA ; la facture, la liste de colisage, le titre de transport et le certificat d'origine arrivent en PDF ou en scan, et aucun système ne les lit. L'inspecteur du couloir orange les compare à la main. SmartClearance TN lit ces pièces, les recoupe avec la déclaration et signale les incohérences avec leur preuve.

Principe directeur, appliqué partout : l'outil ne conclut jamais à la fraude. Il produit un **doute motivé** au sens de la Décision 6.1 de l'Accord de l'OMC sur l'évaluation en douane — la douane n'a pas à prouver la fraude, elle doit motiver son doute par écrit ; l'importateur justifie ; la décision reste à l'inspecteur.

2. Approche technique

Quatre agents, organisés en graphe de dépendances et non en exécution parallèle plate :

Agent	Rôle
Inspecteur documentaire	Lit les 4 pièces + la DDM, applique 16 contrôles croisés
Analyste de prix	Compare le prix au kilo à un barème de référence
Profileur	Historique de l'opérateur, comportement, réseau de fournisseurs
Coordinateur	Pondère, score, recommande, explique

L'Inspecteur s'exécute en premier : il produit la date, la référence de la facture et le code SH de la marchandise réellement décrite, dont les trois autres modules dépendent. **Ce lien est ce qui rend le système agentique** : quand la désignation ne correspond pas au code déclaré, l'Analyste refait le contrôle de prix sous le code décrit, et révèle une sous-évaluation masquée par un faux classement — invisible pour chaque agent isolé.

Deux niveaux d'alerte. Niveau 1, les contradictions qui n'admettent aucune explication légitime : écarts de quantité, de poids, de valeur, d'origine, erreurs de calcul, code SH inexistant, référence de facture déjà utilisée, autorité émettrice incohérente. Niveau 2, les écarts qui peuvent s'expliquer : sous-évaluation, poids invraisemblable, désignation vague. Une remise explique un prix bas ; elle n'explique pas 320 pièces contre 200.

Qualification du doute plutôt que verdict. Un justificatif de remise atténue l'alerte de prix ($\times 0,4$) *si la remise couvre l'écart constaté* ; sinon il la **renforce** ($\times 1,2$). Une mention « brand new original » sur un prix à -70% aggrave le doute. Le profil de l'opérateur est plafonné à 40 points et ne peut jamais, seul, déclencher un contrôle physique : il oriente le regard, il n'accuse pas. Un opérateur inconnu ne produit aucune alerte.

Aucune valeur déclarée n'est corrigée. La déclaration est un acte juridique : le système normalise une copie de travail, garde la valeur brute et affiche toute normalisation. Une saisie douteuse est signalée, jamais substituée.

Comparer ce qui est comparable. Le barème est en valeur CIF ; un prix sous un autre incoterm y est ramené avant comparaison (FOB, FCA, FAS, EXW : $\times 1,10$) et l'alerte affiche la conversion. Un incoterm inconnu n'est pas converti d'office : il passe dans les éléments non lus. Sans cela, un prix FOB comparé à un barème CIF produirait une sous-évaluation par simple construction.

Le système dit aussi quoi demander. Chaque type d'alerte est associé aux pièces à réclamer — contrat commercial, preuve de paiement, justification de remise ; le coordinateur compose la liste à partir des alertes levées et l'affiche avec l'explication.

3. Données et modèles

Entrée : 3 jeux de 20 dossiers synthétiques (facture, colisage, transport, certificat d'origine en PDF ; DDM en JSON), générés avec vérité terrain. Les scripts d'amorçage et le premier jeu ont été produits les 22-23 septembre avec assistance IA, avant l'ouverture du hackathon ; tout le reste a été développé pendant l'événement.

Références : barème de prix construit à partir d'UN Comtrade (imports tunisiens 2021-2023), assorti de deux séries d'indices saisonniers mensuels reconstituées côté partenaires déclarants (voir §5) ; nomenclature du Système Harmonisé 2022 à 6 chiffres, 5 612 positions, données ouvertes issues de la classification de l'ONU ; liste de juridictions sous surveillance renforcée, d'illustration, à remplacer par la liste officielle du GAFI.

Outils : Python 3.14, pdfplumber, pandas, scikit-learn, Streamlit, python-dotenv, reportlab (génération du jeu de test), SQLite. Modèle de langage gemini-3.8-flash (Google AI Studio), appelé par requête HTTP directe.

Périmètre du modèle de langage : il rédige uniquement l'explication destinée à l'inspecteur. Il ne calcule aucun score, ne choisit aucune recommandation, ne crée aucune alerte. Un contrôle de sortie rejette toute réponse contenant le mot « fraude » ou un nombre absent des données d'entrée. Tout ce qui fonde une décision reste déterministe et reproductible.

4. Résultats obtenus

Jeu	Rôle	Anomalies posées	Rappel	Précision	Fausse alertes sur dossiers propres
Graine 7	calibrage des seuils	23	23/23	23/23	0/6
Graine 99, 1re mesure	1er jeu indépendant	19	18/19	18/18	0/6
Graine 99, état final	même jeu, enrichi depuis	23	23/23	23/23	0/6
Graine 123	indépendant, après correction	23	23/23	23/23	0/6

La ligne en gras est celle qui nous a appris quelque chose. Le premier jeu indépendant a révélé un défaut d'architecture : un faux classement masquant une sous-évaluation n'était vu par aucun agent, faute de transmission entre eux. Nous avons créé le lien

Inspecteur → Analyste, puis mesuré sur un troisième jeu jamais utilisé pour le réglage. La graine 99 a depuis été enrichie de quatre anomalies, ses dix-neuf d'origine inchangées ; le dossier qui avait échappé au système est aujourd'hui détecté — score 94, contrôle physique. Les deux lignes ne se comparent donc pas terme à terme : nous gardons la première parce qu'elle est la seule mesure faite sur un jeu que nous n'avions pas vu.

Une convention de comptage, visible dans le code d'évaluation. Quand un justificatif couvre l'écart, l'alerte est émise sous le nom `sous_evaluation_justifiee`, avec une gravité réduite, et l'évaluation la compte comme détectée : elle existe, elle est affichée, elle est motivée.

Profileur, évalué seul : 9 schémas cachés sur 9 retrouvés, aucune fausse alerte sur 21 opérateurs normaux, dérive de prix mesurée à -5,3 % par trimestre pour -5 % posés.

Performance : 90 ms par dossier, dont 92 % en lecture des PDF. L'exécution parallèle n'apporte aucun gain mesurable ; le séquentiel est conservé. SQLite n'accélère rien face aux CSV (120 ms contre 112) mais apporte l'atomicité du registre.

Robustesse du module de langage. Quatre modes de panne rencontrés en conditions réelles — modèle retiré du catalogue, quota gratuit atteint, service surchargé, délai dépassé — tous absorbés par le générateur déterministe, sans un seul écran vide. **Au moment du dépôt, le quota gratuit est épuisé : les soixante explications sont produites sans le modèle.** Aucune décision n'en dépend, et c'est précisément ce que nous voulions démontrer.

5. Limites identifiées

- **Les trois jeux proviennent du même générateur**, avec six produits et une seule maquette de document. Ces chiffres valident la chaîne de bout en bout, pas la robustesse sur des dossiers réels. Les seuils ont été calibrés sur la graine 7.
- **L'extracteur ne lit que la maquette de notre générateur.** Il repère des libellés fixes (« Net weight », « Ref: », l'en-tête DESCRIPTION/QTY) et exige deux espaces entre colonnes. Une facture réelle, d'une autre mise en page, serait en grande partie non lue : les champs manquants sont affichés comme tels et rien n'est deviné, mais peu de contrôles s'exécuteraient. Les PDF sont par ailleurs natifs, non des scans tamponnés. L'extraction par modèle de langage, prévue au projet, n'a pas été construite.
- **Le 9/9 du Profileur est circulaire** : il retrouve des schémas que le même projet a posés dans un historique fabriqué.
- Deux contrôles du Profileur (ancienneté de l'importateur, fournisseur inconnu) et le contrôle des juridictions surveillées sont codés mais ne se déclenchent sur aucun jeu.
- Le barème ne compte que six lignes ; un prix a été déplacé d'une position tarifaire à une autre sans nouvelle donnée Comtrade.
- Les taux de change sont des taux d'illustration, non les taux officiels de la BCT.
- **Le système chiffre la valeur non déclarée, pas les droits ni la TVA édulés** : leur calcul exige le tarif douanier par code SH, qui n'est pas publié en fichier.
- La nomenclature est le SH international à 6 chiffres, en anglais : elle vérifie l'existence d'un code et affiche son libellé, elle ne classe pas une marchandise.
- L'extension du contrôle désignation/code SH aux 5 612 positions a été mesurée puis **écartée** : elle produisait un faux positif.
- La boucle d'apprentissage de niveau 3 est **livrée inactive**, démontrée sur des retours synthétiques étiquetés comme tels, et les alertes de niveau 1 ne sont jamais apprises. Trois garde-fous volontaires la bornent : gravité jamais inférieure à 0,6 fois sa valeur initiale ; un justificatif qualifie une alerte, il ne l'éteint pas ; toute alerte sur les pièces impose un score plancher de 30, donc un contrôle documentaire au minimum. Un système capable d'apprendre à ne plus rien voir ne serait pas déployable. Ce qu'elle fait est donc modeste et mesurable : gravité 35 → 29 → 25, score 61 → 60 → 59, recommandation inchangée.
- **La correction saisonnière est marginale : deux séries d'indices sur six couples.** La Tunisie ne déclarant pas ses importations à Comtrade, l'historique mensuel est reconstitué depuis les pays d'origine. La règle — 24 observations mensuelles, 2 par mois calendaire, amplitude ≥ 1,10, indice borné à 0,80-1,25 — a été posée avant toute mesure et n'a été franchie que par deux positions : téléviseurs depuis la Chine (852872) et voitures de 1 000 à 1 500 cm³ depuis l'Espagne (870322). Sur les trois jeux, l'ajustement **ne change aucune alerte, aucun score, aucune recommandation** : six écarts de prix bougent, tous sur des dossiers sans alerte de prix. Le mécanisme est en place et sans effet de bord, pas démontré utile ; sur les quatre positions non couvertes, un produit saisonnier peut déclencher une alerte hors saison ou en éviter une pendant.
- Une mesure du réseau de fournisseurs (\$4.4 du projet) a été conduite puis **non branchée** : ses seuils dérivait d'un unique nœud que nous avons nous-mêmes placé dans l'historique, et le contrôle existant couvre déjà le même fait.
- Le générateur d'historique a été corrigé après deux fausses alertes venant d'une incohérence entre deux générateurs : correction d'un artefact, non d'un seuil.
- **Défaut connu, non corrigé : un champ absent de la déclaration éteint les contrôles qui en dépendent, et le système ne le dit pas assez fort.** Retirer le seul poids net de la DDM d'un dossier noté 85 avec contrôle physique le fait ressortir à 0 avec libération : l'écart de poids avec la liste de colisage n'est plus calculé, faute de terme de comparaison, et aucune ligne ne signale que le poids manque. Le système affiche bien que l'Analyste de prix n'a pas été exécuté, mais un bandeau vert reste un bandeau vert. Il faut qu'une **déclaration incomplète soit elle-même un motif de contrôle** — un champ obligatoire absent doit produire une alerte de niveau 1, pas un silence. Nous avons trouvé ce défaut en construisant le mécanisme de préconditions, quelques heures avant le dépôt, et nous avons choisi de le documenter plutôt que de modifier une règle de score sans pouvoir la re-mesurer sérieusement. C'est la première correction que nous apporterons.

6. Recommandations pour une mise en production

1. **Pilote sur un seul bureau de dédouanement**, couloir orange, sur trois mois, avec mesure du taux de confirmation des alertes par les inspecteurs.
2. **Branchement sur SINDA et TTN** pour recevoir les pièces jointes réelles et l'historique des opérateurs — c'est ce qui rend le Profileur exploitable.
3. **Intégration du tarif douanier tunisien**, avec les positions nationales et les taux, pour chiffrer les droits et la TVA en jeu. Nécessite une convention avec la DGD.
4. **Modèle de langage open-weight hébergé sur les serveurs de l'administration.** Des données douanières ne doivent pas transiter par une API étrangère. L'architecture ne dépend d'aucun fournisseur : le module de rédaction est isolé derrière une interface et fonctionne sans lui.
5. **Mesure continue de l'écart.** Chaque dossier contrôlé produit une trace exploitable. Après quelques mois, la douane disposerait d'une estimation chiffrée de la sous-déclaration — la dernière estimation publiée sur la Tunisie date de 2015.